

예측 모델을 통해 고위험 지역을 식별하여 맞춤형 교통안전 정책을 제안

서울특별시 대상 면허소지자 프로파일과 교통안전 상관관계 분석

소프트웨어융합학과 202111402 이예은

빅데이터분석 기말 프로젝트 최종 발표

agenda

프로젝트 개요

프로젝트 구성 및 설계

Dataset 개요

데이터 전처리 및 파생지표 생성

상관관계 분석

EDA (분포/이상치/상관관계)

공간 시각화

클러스터링 & 프로파일

분류, 예측 모델링

가설 검증 & 정책 제안

→ 프로젝트 개요

프로젝트 구성 및 설계

Dataset 개요

데이터 전처리 및 파생지표 생성

상관관계 분석

EDA (분포/이상치/상관관계)

공간 시각화

클러스터링 & 프로파일

분류, 예측 모델링

가설 검증 & 정책 제언

운전면허 보급 구조(성별·종별·지역별 면허율)
와 지역별 교통사고 발생률·사망률 간의 상관
관계를 분석하고, **예측 모델**을 통해 고위험 지
역을 식별하여 **맞춤형 교통안전 정책을 제안하**
는 프로젝트

서울특별시 대상 면허소지자 프로파일과 교통안전 상관관계 분석



연구 배경

①

사회/경제적 손실 현황

국내 교통사고로 인한 사회적 비용은 약 43조 7,669억 원으로 추산 → GDP의 2% 수준

물리적 피해 비용은 약 24조 5,003억 원
정신적 고통 비용은 약 19조 2,666억 원

②

데이터 맞춤형 정책 필요성

고위험 요인·지역별 맞춤 대책 없이 예산과 인력이 낭비될 가능성이 있음. 빅데이터 분석으로 “언제·어디서·누구에게” 집중 투입

패턴 분석으로 사고 다발 시간·장소 예측해, 사전 예측 기반 예방 효과 누리기 가능

③

인구/차량 대비 사고 집중

전국 시도 중 서울시는 1만 대당 교통사고 발생 건수가 1.9건, 인구 10만 명당 사망자 수가 9.1명으로 높은 편에 속함

차량 등록 대수가 많은 자치구일수록 절대 사고 건수도 높아, 차량 밀집도가 안전 수준에 중요한 영향을 미칠 가능성이 있음

프로젝트 개요

문제 정의

사고 다발 지역과 안전 취약 요인을 정확히 파악하지 못해, 예산·인력 배분의 우선순위를 정하기 어려움

면허·인구·차량·인프라·경제 지표가 분산되어 분석되지 못해, 종합적 안전 관리 전략 수립에 한계

서울시 자치구별 교통사고 발생·사망률에 큰 차이가 있음에도,

일괄적 대책만 적용되어 실효성이 낮아, 고위험 지역을 식별하여 맞춤형 교통안전 정책을 제안

프로젝트 개요

기대 효과

1 사고 예방 효율성 극대화

고위험 지역·요인을 정확히 식별해,
맞춤형 안전 대책을 우선 실행함으로써 사고 건수·사망률 감소

2 자원 배분 최적화

데이터 기반 우선순위 설정으로 한정된 예산과 인력을 효율적으로 투입하여 정책 비용 대비 효과 극대화

3 지속 가능한 안전 관리

통합 지표 모니터링 체계 구축으로 정책 성과를 지속적으로 평가·개선하여 장기적 교통안전 수준 향상

4 시각화 모니터링

추후 정책 및 사고 모니터링이 도움이 되는 시각화 자료 제공

프로젝트 개요

EDA (분포/이상치/상관관계)

→ **프로젝트 구성 및 설계**

공간 시각화

Dataset 개요

클러스터링 & 프로파일

데이터 전처리 및 파생지표 생성

분류, 예측 모델링

상관관계 분석

가설 검증 & 정책 제안

프로젝트 구성 요약

1. 데이터 통합

면허·인구·사고·인프라·경제·차량 6개 데이터셋 병합

2. 전처리 & 파생지표 생성

region_code 통일, 결측치·이상치 처리, 9가지 파생변수 생성

3. EDA & 가설 검증

히스토그램·박스플롯, 상관행렬 히트맵, 산점도+회귀선으로 H1-H3 검증

4. 공간 시각화

서울시 자치구별 Choropleth 지도(사고율, 면허율:차량율 비교)

5. 클러스터링 & 모델링

- Means 세그멘테이션 (silhouette 최적 K)
- RandomForest:XGBoost 분류, LightGBM·RF 회귀

6. 정책 인사이트 & 제안

목표

데이터 기반 고위험 지역 식별
지역 특성별 맞춤형 교통안전 정책 제안

데이터

공공데이터포털·도로교통공단·통계청 등 6종 (CSV/JSON/API)
면허소지·인구·사고·도로·경제·차량등록 정보


평가 지표

- 클러스터링 품질: Silhouette Score
- 분류 모델: Precision, Recall, F1-Score

ROC-AUC

프로젝트 구성 파이프라인

분석 파이프라인 (FlowChart)



가설 설정

- ① 면허율이 높을수록 사고율은 낮다
- ② 1인당 GRDP가 높은 지역일수록 사고율은 낮다
- ③ 차량 1대당 사고 발생률이 높은 지역은 고위험 클러스터로 분류된다


프로젝트 개요	EDA (분포/이상치/상관관계)
프로젝트 구성 및 설계	공간 시각화
→ Dataset 개요	클러스터링 & 프로파일
데이터 전처리 및 파생지표 생성	분류, 예측 모델링
상관관계 분석	가설 검증 & 정책 제안

DATASET 개요

공공데이터 포털 및 서울시 '공공 데이터셋' 활용

공공데이터포털, 행정안전부, 도로교통공단, 국토교통부, 통계청 등에서 제공하는 총 6개 데이터셋을 수집 및 통합

→ 서울시 자치구 단위로 면허 보급 구조와 교통안전 지표 간 상관관계를 분석에 적합



DATASET 분석

데이터셋 구조 분석

1. 운전면허 보급 (license.xlsx)

: 자치구별·연령·성별·면허 종류별 운전면허 소지자 수 현황

Dataset 구조

행·열 수: 217행 × 6열

주요 컬럼

- region_code (자치구 코드)
- 연령대
- 성별
- 1종소계, 2종소계, 2종 원자

출처: 공공데이터포털 운전면허소지자 지역별 종별 현황

DATASET 분석

데이터셋 구조 분석

2. 인구 통계 (population.xlsx)

: 자치구별 주민등록 인구 및 세대 구조

Dataset 구조

행·열 수: 26행 × 41열

주요 컬럼

- region_code (자치구 코드)
- 총 거주자수
- 연령·성별 인구수 (0~9세, 10대, ..., 80세 이상)
- 1인 가구 비율, 세대수

출처: 행정안전부 주민등록인구 통계

DATASET 분석

데이터셋 구조 분석

3. 교통사고 통계 (accident.xlsx)

: 사고유형별·자치구별 사고 건수 및 사상자 수

Dataset 구조

행·열 수: 80행 × 8열

주요 컬럼

- region_code (자치구 코드)
- 구분별 (발생건수/사망자수/부상자수)
- 2024년도 건수
- 차대사람, 차대차, 차량단독

출처: 도로교통공단 교통사고 통계 API

DATASET 분석

데이터셋 구조 분석

4. 인구밀도 (population_density.xlsx)

: 자치구별 면적 대비 인구분포 현황

Dataset 구조

행.열 수: 26행 × 5열

주요 컬럼

- region_code (자치구 코드)
- 인구 (명)
- 면적 (km²)
- 인구밀도 (명/km²)

출처: 서울시 생활인구.행정동별 인구밀도 데이터

DATASET 분석

데이터셋 구조 분석

5. 자동차 등록 현황 (car_registration.xlsx)

: 자치구별 차종별 등록 차량 수 현황

Dataset 구조

행·열 수: 27행 × 22열

주요 컬럼

- region_code (자치구 코드), 시군구
- 차종별 등록대수 (승용, 승합, 화물, 특수, ...)
- 총계

출처: 국토교통부 자동차등록현황

DATASET 분석

데이터셋 구조 분석

6. GRDP 지표 (GDP.xlsx)

: 자치구별 경제 규모 및 1인당 GRDP, 수준지수

Dataset 구조

행·열 수: 26행 × 7열

주요 컬럼

- region_code (자치구 코드), 시군구
- 지역내총생산(백만원)
- 구성비 (%)
- 인구(추계인구) (명)
- 1인당 지역내총생산 (천원)
- 수준지수 (서울=100) (%)

출처: 통계청 자치구별 GRDP 및 수준지수

개발 환경 구축

실험환경 (개발 환경 세팅)

Google Colab Pro

GPU T4

python 3

Google Drive One

2TB

Google Drive Mount

문서화

Notion

Github

개발 환경 구축

프로젝트 폴더 구조

프로젝트 폴더 구조

- data/raw/ -> 원본 데이터
- data/clean/ -> 전처리 데이터
- notebooks/ -> 분석·모델링 노트북
- scripts/ -> 수집·전처리 스크립트

개발 환경 구축

개발에 사용한 주요 라이브러리

데이터 처리

pandas

numpy

시각화

matplotlib

seaborn

지리공간 분석

geopandas

(Choropleth 지도)

개발 환경 구축

개발에 사용한 주요 라이브러리

머신러닝 & 모델링

scikit-learn

(전처리, K-Means, RandomForest, 평가 지표)

lightgbm (회귀 모델)

xgboost (분류 모델)

shap (SHAP 값 기반 변수 중요도)

환경세팅

google-colab

fonts-nanum

프로젝트 개요

EDA (분포/이상치/상관관계)

프로젝트 구성 및 설계

공간 시각화

Dataset 개요

클러스터링 & 프로파일

→ **데이터 전처리 및 파생지표 생성**


분류, 예측 모델링

상관관계 분석

가설 검증 & 정책 제안

데이터 전처리 & 파생지표 생성

데이터 분석 파이프라인 (FlowChart)



데이터 전처리

컬럼명 통일 : 지역코드 → region_code

- 결측, 이상치 처리, 콤마 제거 (to_numeric → fillna(0))
 - 면허/사고 데이터 집계 (license_agg, acc_agg)
- 6개 데이터셋 통합 (inner merge → merged_df_)

✓ 데이터 전처리

- 컬럼명 표준화 : 모든 DataFrame에서 '지역코드' 칼럼을 'region_code'로 통일

기본 구조 점검

- df.shape로 행·열 개수 확인
- df.columns.tolist()로 컬럼명을 리스트로 확보
- df.head() / df.info() / df.describe() 로 주요 값·타입·통계 요약 확인

컬럼 목록 추출

- 각 DataFrame의 columns.tolist() 결과를 모아 데이터별 컬럼 구성을 파악

license_rate

license_total ÷ 총 거주자수

vehicle_rate

total_vehicles ÷ 총 거주자수

accident_rate

accidents ÷ 총 거주자수

fatality_rate

deaths ÷ accidents (치명률)

injury_rate

injuries ÷ accidents (부상률)

파생변수 생성

raw 데이터셋 기반으로 파생변수 계산 후, 생성

accident_per_vehicle

accidents ÷ total_vehicles

accident_per_license

accidents ÷ license_total

accident_per_gdp

accidents ÷ total_gdp

gdp_per_capita

(1인당 지역내총생산)

파생변수 생성

raw 데이터셋 기반으로 파생변수 계산 후, 생성

파생변수 생성

생성된 파생변수 확인

index	region_code ▲	license_rate	vehicle_rate	accident_rate	fatality_rate	injury_rate	accident_per_vehicle	accident_per_license	accident_per_gdp	gdp_per_capita
0	111123	0.7434355917417854	0.026235824367548705	0.01581128234952021	0.0	0.0	0.6026600166251039	0.021267857666696	6.0891046824039184e-05	238599
1	111131	0.7571927370957005	0.0026342636275247023	0.009837777256246797	0.0	0.0	3.7345454545454544	0.012992434784808845	0.00015449835422395793	58918
2	111141	0.6931164624362218	0.0009164828692824991	0.005429785392765495	0.0	0.0	5.924590163934426	0.007833871632020463	0.0002756693639650255	18732
3	111142	0.6860633046312565	0.0013823560439880243	0.007570218230365997	0.0	0.0	5.476315789473684	0.011034285290094065	0.00014864399320766236	48682
4	111151	0.6319872101645534	0.0006547428096617951	0.007441454423063776	0.0	0.0	11.365461847389557	0.011774691486440381	0.0005822755327821125	12742
5	111152	0.6694134569093588	0.0009067361338779657	0.010133588519007494	0.0	0.0	11.175895765472312	0.015138011365641876	0.00044493302208338363	22164
6	111161	0.6517001419253032	0.000677640012036403	0.006920931731322843	0.0	0.0	10.213286713286713	0.010619810072277242	0.00045841942756737636	14608
7	111171	0.6332784281814364	0.0009056068878622428	0.003930858882822344	0.0	0.0	4.340579710144928	0.006207157401698419	0.0003431993108512002	11233
8	111181	0.6359842116962068	0.0006474154097815836	0.006029595516432482	0.0	0.0	9.313333333333333	0.00948073144827165	0.0005465365933047898	11139
9	111191	0.6768331288829093	0.0014872119557331855	0.006361046258557239	0.0	0.0	4.277161862527716	0.009398248973208413	0.00021340660330256952	28793

Show 25 per page

각 지역코드 별, 파생변수 각각의 값 확인 가능


→ 9개 지표로 “인구/차량/면허/경제 대비 사고 위험도”를 다각도로 측정하여, 이후 EDA·모델링에 활용

파생변수 생성


생성된 파생변수간의 관계 시각화

각각의 파생변수 조합해 시각화 가능한 코드 작성


Distributions




2-d distributions




Time series



Values



Distributions



2-d distributions



프로젝트 개요

프로젝트 구성 및 설계

Dataset 개요

데이터 전처리 및 파생지표 생성

→ **상관관계 분석**

EDA (분포/이상치/상관관계)

공간 시각화

클러스터링 & 프로파일

분류, 예측 모델링

가설 검증 & 정책 제안

상관관계 분석

1. 면허율, 사고율 상관관계

모델별(Baseline, EasyOCR, 재학습 모델) 평균 CER

2. GRDP과 사고율 상관관계

샘플 이미지, GT 텍스트별 CER 결과 도출

3. 자동차 등록대수와 사고율 상관관계

Epoch별 CER 변화

4. 인구밀도와 사고율의 상관관계

합성 이미지 개수 증가에 따른 CER 변화


5. 사고가 많은 자치구 상위 10개 대상, 사고 유형 비율 분석

SSIM/FID 결과 비교

상관관계 분석

1. 면허율, 사고율 상관관계

- X축은 자치구별 면허율(0.60-0.76)
- Y축은 인구 대비 사고율(0.004-0.016)




→ 면허율과 사고율 간 **양(+)**의 상관관계를 보임

→ 예상과 달리, **면허율이 높은 지역일수록 사고율도 다소 높은 경향**이 관찰됨.

상관관계 분석

2. GRDP과 사고율 상관관계

- X축: 자치구별 1인당 GRDP (천원)
- Y축: 인구 대비 사고율
- 낮은 GRDP 구간에서도 사고율이 0.004~0.008로 분포,
- 반면 높은 GRDP 자치구(200,000~500,000천원)에서 오히려 사고율이 0.016~0.018로 높게 나타남



→ GRDP와 사고율 간 **양(+)**의 상관을 보임

→ 예상과 달리, **경제 수준이 높은 지역일수록 교통량·활동량 증가로 사고율이 높을 수 있음**이 관찰됨.

상관관계 분석

3. 자동차 등록대수와 사고율 상관관계

	region_code	차대사람	차대차	차량단독
0	111121	506	1634	88
1	111123	460	1598	117
2	111131	352	1639	63
3	111141	379	1395	33
4	111142	392	1640	49

차와 관련된 교통사고 데이터 정제


	region_code	total_vehicles
0	0	12850
1	111121	1298
2	111123	3609
3	111131	550
4	111141	305

각 자치구별 차량대수 총합

상관관계 분석

3. 자동차 등록대수와 사고율 상관관계

- X축: 자치구별 총 등록 차량 수 (대수)
- Y축: 차량 1만대당 사고 건수
- 차량 적은 자치구에서
사고율이 40,000-120,000으로 높게 나타나고,
- 차량 많은 자치구에서
사고율이 5,000-20,000으로 낮게 분포




→ 자동차 등록대수와 사고율 간 **음(-)의 상관**을 보임

→ 예상과 동일하게, **차량 수가 많을수록 차량 1대당 사고율이 감소하는 경향**이 관찰됨.

상관관계 분석

4. 인구밀도와 사고율의 상관관계

- X축: 자치구별 인구밀도 (7,000–25,000명/km²)
- Y축: 인구 대비 사고율 (0.004–0.018)




→ 자동차 등록대수와 사고율 간 음(-)의 상관을 보임

→ 예상과 다르게, **중간 밀집(12,000–15,000)** 구간에서 오히려 **최고 사고율이 관찰됨**.

5. 사고가 많은 자치구 상위 10개 대상, 사고 유형 비율 분석

• 총 사고 건수 Top 3

- 111261 (강남구): 약 6,800건
- 111273 (송파구): 약 4,800건
- 111262 (서초구): 약 4,200건



- 차대차 사고(초록색)가 전체 사고의 85-90%를 차지
- 차대사람(진한 파랑), 차량단독(연두) 사고는 각각 약 5-10% 수준
- 특히 111261 강남구는 차대차 사고 비중이 95%에 달해, 충돌 사고 예방이 시급

상관관계 분석

인사이트

- **종로구, 구로구** 등 비교적 차량 수가 적은 구들은
 - **차대차 비중이 다소 낮음(80%대)**
 - 차대사람·차량단독 사고 비율이 상대적으로 높음(20%)
- 차량 밀집·도로망이 발달한 강남구·송파구에서는
 - **순수 충돌(차대차) 사고가 압도적**
- **차대차 사고가 절대 다수를 차지하므로,**
 - 교차로 신호 최적화, 차선 분리대 강화
 - 차량 간 거리 경고 시스템 도입 등의 대책 집중 필요
- **차대사람·차량단독 사고가 상대적으로 많은 구는**
 - 보행자 안전 강화(횡단보도 개선, 감속 유도)
 - 단독 사고 다발 지점에 방지턱·속도제한 등의 맞춤형 대책 검토

프로젝트 개요

→ EDA (분포/이상치/상관관계)

프로젝트 구성 및 설계

공간 시각화

Dataset 개요

클러스터링 & 프로파일

데이터 전처리 및 파생지표 생성

분류, 예측 모델링

상관관계 분석

가설 검증 & 정책 제안

EDA(탐색적 데이터 분석) 개요

- 각 지표들이 지역별로 어떻게 분포하고 서로 어떤 관계를 가지는지
- merged_df에 생성된 파생 변수들을 중심으로 EDA 진행
 1. 변수 분포 확인 (히스토그램, 박스플롯)
 2. 상관관계 분석 (히트맵, pairplot)
 3. 상관성 있는 조합 간 산점도 시각화
 4. 이상값(outlier) 탐지 (z-score)
 5. 요약 인사이트 도출

```
# 2. 상관관계 히트맵
corr_matrix = merged_df[eda_vars].corr()

plt.figure(figsize=(10, 8))
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', fmt=".2f")
plt.title("🔥 파생 변수 간 상관관계 히트맵")
plt.tight_layout()
plt.show()



# 3. 주요 상관조합 산점도 (상위 상관계수 조합만)
from itertools import combinations

high_corr_pairs = []
for x, y in combinations(eda_vars, 2):
    corr_val = merged_df[x].corr(merged_df[y])
    if abs(corr_val) > 0.6:
        high_corr_pairs.append((x, y, corr_val))

# 시각화
for x, y, corr_val in high_corr_pairs:
    plt.figure(figsize=(6, 4))
    sns.scatterplot(x=merged_df[x], y=merged_df[y])
    plt.title(f'{x} vs {y} (corr={corr_val:.2f})')
    plt.xlabel(x)
    plt.ylabel(y)
    plt.tight_layout()
    plt.show()

# 4. 이상값 탐지 (z-score 기준)
z_scores = merged_df[eda_vars].apply(zscore)
outlier_flags = (np.abs(z_scores) > 3).sum(axis=1)
outliers = merged_df[outlier_flags > 0]

print(f"이상값 포함 자치구 수: {outliers.shape[0]}")
display(outliers[['region_code'] + eda_vars])
```



1. EDA: 파생 지표 상관관계 분석 주요 결과


1. EDA: 파생 지표 상관관계 분석 주요 결과

- 파생 지표 9종(`license_rate`, `vehicle_rate`, `accident_rate` 등)의 분포 확인
- 이상치 탐지를 위한 Z-score 기준($|z| > 3$) 적용

변수 조합	상관계수	해석
<code>gdp_per_capita</code> vs <code>accident_rate</code>	+0.89	1인당 GRDP가 높은 지역일수록 사고율도 높음 → 예외적
<code>license_rate</code> vs <code>accident_rate</code>	+0.72	면허 보급률이 높을수록 사고율도 증가 → 운전활동이 많은 지역
<code>accident_rate</code> vs <code>accident_per_license</code>	+0.99	면허 1인당 사고율과 전체 사고율 거의 일치
<code>vehicle_rate</code> vs <code>gdp_per_capita</code>	+0.75	차량 보급률과 지역경제수준의 양의 관계
<code>license_rate</code> vs <code>accident_per_gdp</code>	-0.81	면허율 높을수록 GDP 대비 사고 비율 낮음 → 운전 인프라 효율적
<code>injury_rate</code> vs <code>accident_rate</code>	-0.17	사고율 높다고 반드시 부상률도 높은 건 아님 → 사고 유형 차이 가능성

2. EDA: 파생 지표 상관관계 히트맵

- 면허율 ↔ 사고율: $r = +0.73$
- 면허율 ↔ GDP 대비 사고율: $r = -0.81$
- 사고율 ↔ 면허당 사고율: $r = +0.99$
- 사고율 ↔ 1인당 GRDP: $r = +0.90$




EDA

3. EDA: 주요 상관 조합 산점도

- 가설 검증용 핵심 지표 3쌍 산점도 + 회귀선

1. 면허율 vs 사고율 (`license\_rate` vs `accident\_rate`)




EDA

3. EDA: 주요 상관 조합 산점도

- 가설 검증용 핵심 지표 3쌍 산점도 + 회귀선

2. GRDP vs 사고율 (`gdp\_per\_capita` vs `accident\_rate`)




EDA

3. EDA: 주요 상관 조합 산점도

- 가설 검증용 핵심 지표 3쌍 산점도 + 회귀선

3. 차량당 사고율 vs 사고율 (`accident\_per\_vehicle` vs `accident\_rate`)



4. EDA: 이상치 탐지 결과

- 이상치 포함 자치구: 1개 → 강남구 (111123)

이상값 포함 자치구 수: 1

	region_code	license_rate	vehicle_rate	accident_rate	fatality_rate	injury_rate	accident_per_vehicle	accident_per_license	accident_per_gdp	gdp_per_capita
0	111123	0.7434	0.0262	0.0158	0.0000	0.0000	0.6027	0.0213	0.0001	238599


- 높은 면허율 (74.3%), 높은 차량율 (2.62%)
- 사고율(1.58%) 및 면허당 사고율(2.13%) 상위
- GDP 대비 사고율(0.0001) 최저 구간

→ 모든 비율 지표에서 극단적인 수치를 보임 → 모델링 전 로그 변환 또는 클리핑 대상

공간 시각화

서울시 지도 공간 시각화

- 서울시 자치구 경계(GeoJSON/Shape)와 병합하여
자치구별 사고율 Choropleth 제작
- 사고율 주요 지표를 지도 위에 표현
- 진할수록 사고율(인구 대비) 높음
- **중구·종로구(중앙부)는 진한 주황($\approx 0.012-0.016$)**
 - **인구밀도·교통량 집중 구간에서 사고율 높음**
- 외곽 자치구는 거의 흰색($\approx 0.000-0.004$)
 - 상대적으로 안전



서울시 자치구별 사고율 (2024 기준)

프로젝트 개요

EDA (분포/이상치/상관관계)

프로젝트 구성 및 설계

공간 시각화

Dataset 개요

→ **클러스터링 & 프로파일**

데이터 전처리 및 파생지표 생성

분류, 예측 모델링

상관관계 분석

가설 검증 & 정책 제안

클러스터링 & 프로파일

K-Means 클러스터링 개요

1. 클러스터링 대상 변수: 파생변수
2. 결측치 제거 및 지역 코드 포함
3. 표준화
4. 최적 클러스터 수 탐색 (2~8 범위)
5. 최적 K 선택
6. 최종 모델 학습 및 클러스터 할당, 병합
7. 클러스터별 평균값 확인, 결과 출력

Loading...

```
# 1. 결측치 제거 및 지역코드 포함
cluster_df = merged_df[['region_code'] + cluster_features].dropna()

# 2. 표준화
scaler = StandardScaler()
X_scaled = scaler.fit_transform(cluster_df[cluster_features])

# 3. 최적 클러스터 수 탐색 (2~8 범위)
silhouette_scores = {}
for k in range(2, 9):
    kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
    labels = kmeans.fit_predict(X_scaled)
    score = silhouette_score(X_scaled, labels)
    silhouette_scores[k] = score

# 4. 최적 K 선택
best_k = max(silhouette_scores, key=silhouette_scores.get)
print(f"▶ 최적 K: {best_k}, Silhouette Score: {silhouette_scores[best_k]:.3f}")

# 5. 최종 모델 학습 및 클러스터 할당
final_kmeans = KMeans(n_clusters=best_k, random_state=42, n_init=10)
cluster_labels = final_kmeans.fit_predict(X_scaled)
cluster_df['cluster'] = cluster_labels

# 6. 병합하여 활용 가능하게 만들
merged_df = merged_df.merge(cluster_df[['region_code', 'cluster']], on='region_code')

# 7. 클러스터별 평균값 확인
cluster_profile = (
    cluster_df
    .groupby('cluster')[cluster_features]
    .mean()
    .round(4)
)
```


K-Means 클러스터링 결과

- 최적 클러스터 수 (K): 2
- Silhouette Score: 0.452

▶ 최적 K: 2, Silhouette Score: 0.514
▶ 클러스터 프로파일

	license_rate	vehicle_rate	accident_rate	fatality_rate	accident_per_license	accident_per_vehicle	accident_per_gdp	gdp_per_capita
cluster								
0	0.7410	0.0073	0.0141	0.0000	0.0191	10.5518	0.0001	149960.0000
1	0.6718	0.0009	0.0072	0.0000	0.0107	8.6544	0.0003	28363.5500

클러스터링 & 프로파일

인사이트

클러스터 0: 고소득 & 고면허·고위험 그룹

- 1인당 GRDP: 약 131,751천원 (매우 높음)
- 면허율: 74.4% (전국 상위권)
- 사고당 차량수/면허당 사고 비율 모두 상대적으로 높음
- 치명률(fatality_rate)도 높은 편

“

"경제력은 높지만,

면허 보급도 많고

운전 노출도가 높아

사고도 많이 발생하는 고위험 지역"

클러스터링 & 프로파일

인사이트

클러스터 1: 저소득 & 저면허·저위험 그룹

- 1인당 GRDP: 26,755천원 (저소득)
- 면허율: 66.7%
- 사고 관련 모든 비율이 상대적으로 낮음

“

"운전 노출이 낮고,

차량 수가 적어

교통사고 발생률도 낮은

저위험 지역"

프로젝트 개요

EDA (분포/이상치/상관관계)

프로젝트 구성 및 설계

공간 시각화

Dataset 개요

클러스터링 & 프로파일

데이터 전처리 및 파생지표 생성



분류, 예측 모델링

상관관계 분석

가설 검증 & 정책 제안

분류/예측 모델링

분류 모델링

: 자치구 데이터를 기반으로

“고사고 위험지역(Cluster 0)”을 분류하는 모델 생성

변수

- 종속변수: cluster (0=고위험군, 1=저위험군)
- 입력변수: 파생지표 기반 주요 특성들

모델

- RandomForestClassifier
- XGBoostClassifier

평가

- Precision / Recall / F1-Score (classification_report)
- Support (각 클래스 샘플 수)
- Accuracy
- ROC AUC Score (roc_auc_score)

1. 데이터 준비, 전처리

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler

# 사용 변수 정의
features = [
    'license_rate', 'vehicle_rate', 'accident_rate',
    'fatality_rate', 'injury_rate',
    'accident_per_vehicle', 'accident_per_license',
    'accident_per_gdp', 'gdp_per_capita'
]

X = merged_df[features]
y = merged_df['cluster']

# 학습/테스트 데이터 분리
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42
)

# 정규화
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

분류 모델링

자치구 데이터를 기반으로 “고사고 위험지역(Cluster 0)”을 분류하는 모델

2. Random Forest 모델 학습

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report, confusion_matrix, roc_auc_score

# 모델 훈련
rf = RandomForestClassifier(n_estimators=100, random_state=42)
rf.fit(X_train_scaled, y_train)

# 예측 및 평가
y_pred = rf.predict(X_test_scaled)
print("🌟 Random Forest 성능 평가")
print(classification_report(y_test, y_pred))
print("ROC AUC Score:", roc_auc_score(y_test, rf.predict_proba(X_test_scaled)[:,1]))
```

분류 모델링

자치구 데이터를 기반으로 “고사고 위험지역(Cluster 0)”을 분류하는 모델

2. Random Forest 모델 학습

Random Forest 성능 평가		precision	recall	f1-score	support
	0	1.00	1.00	1.00	1
	1	1.00	1.00	1.00	4
	accuracy			1.00	5
	macro avg	1.00	1.00	1.00	5
	weighted avg	1.00	1.00	1.00	5
ROC AUC Score: 1.0					

- 모든 클래스에 대해 **Precision, Recall, F1-Score**가 1.00으로 **완벽한 예측 성능**
- **ROC AUC=1.00**으로 모델이 테스트 데이터를 완벽히 구분

분류 모델링

자치구 데이터를 기반으로 “고사고 위험지역(Cluster 0)”을 분류하는 모델

3. XGBoost 모델 학습

```
import xgboost as xgb

xgb_clf = xgb.XGBClassifier(
    n_estimators=100,
    learning_rate=0.1,
    max_depth=3,
    random_state=42,
    use_label_encoder=False,
    eval_metric='logloss'
)
xgb_clf.fit(X_train_scaled, y_train)

# 예측 및 평가
y_pred_xgb = xgb_clf.predict(X_test_scaled)
print("< XGBoost 성능 평가")
print(classification_report(y_test, y_pred_xgb))
print("ROC AUC Score:", roc_auc_score(y_test, xgb_clf.predict_proba(X_test_scaled)[: ,1]))
```

분류 모델링

자치구 데이터를 기반으로 “고사고 위험지역(Cluster 0)”을 분류하는 모델

3. XGBoost 모델 학습

✂ XGBoost 성능 평가

	precision	recall	f1-score	support
0	1.00	1.00	1.00	1
1	1.00	1.00	1.00	4
accuracy			1.00	5
macro avg	1.00	1.00	1.00	5
weighted avg	1.00	1.00	1.00	5

ROC AUC Score: 1.0

- 모든 클래스에 대해 **Precision, Recall, F1-Score**가 **1.00**으로 **완벽한 예측 성능**
- **ROC AUC=1.00**으로 모델이 테스트 데이터를 완벽히 구분

→ 과적합(overfitting) 가능성 높으므로 교차검증 필요

분류 모델링

자치구 데이터를 기반으로 “고사고 위험지역(Cluster 0)”을 분류하는 모델


4. 변수 중요도 시각화

- “사고율” 지표가 모델 성능을 좌우

→ 우선적으로 모니터링·관리 필요

- 경제력 지표, 비율 기반 사고 지표

→ 정책 우선순위 설정 시 핵심 피처로 활용



분류 모델링

자치구 데이터를 기반으로 “고사고 위험지역(Cluster 0)”을 분류하는 모델

분류/예측 모델링

예측 모델링

: 회귀 모델 & 분류 모델로 구현

① 회귀 모델 (사고율 예측)

자치구별 사고율(연속 값) 예측 및

② 분류 모델 (고위험 지역 예측)

상위 20% “고위험 지역” 이진 분류

분류/예측 모델링

예측 모델링

① 회귀 모델 (사고율 예측)

모델

- RandomForestRegressor
- LGBMRegressor

평가 지표

- MAE (Mean Absolute Error)
- RMSE (Root Mean Squared Error)
- R^2 (결정계수)

```
# — (1) 회귀 모델로 사고율 예측 —————
# 특성 변수 정의 (이전과 동일)
features = [
    'license_rate', 'vehicle_rate', 'accident_per_vehicle',
    'accident_per_license', 'accident_per_gdp',
    'gdp_per_capita'
]

# 입력(X)과 목표(y_reg)
X_reg = merged_df[features]
y_reg = merged_df['accident_rate']

# 학습/테스트 분리
Xr_train, Xr_test, yr_train, yr_test = train_test_split(
    X_reg, y_reg, test_size=0.2, random_state=42
)

# RandomForestRegressor
rf_reg = RandomForestRegressor(n_estimators=100, random_state=42)
rf_reg.fit(Xr_train, yr_train)
yr_pred_rf = rf_reg.predict(Xr_test)

# LightGBM Regressor
lgb_reg = LGBMRegressor(n_estimators=100, random_state=42)
lgb_reg.fit(Xr_train, yr_train)
yr_pred_lgb = lgb_reg.predict(Xr_test)

# 평가 함수
def regression_metrics(y_true, y_pred, name="Model"):
    mae = mean_absolute_error(y_true, y_pred)
    # squared=False 제거하고, np.sqrt를 사용하여 직접 RMSE 계산
    mse = mean_squared_error(y_true, y_pred)
    rmse = np.sqrt(mse)
    r2 = r2_score(y_true, y_pred)
    print(f"--- {name} ---")
    print(f"MAE: {mae:.4f}")
    print(f"RMSE: {rmse:.4f}")
    print(f"R2: {r2:.4f}")
```

분류/예측 모델링

예측 모델링

① 회귀 모델 (사고율 예측) 출력 결과

RandomForestRegressor

- 중간 수준의 설명력 ($R^2 \approx 0.64$)
- 평균적으로 사고율 예측 오차 $\approx 0.17\%$ 포인트

LGBMRegressor

- 과소적합 or 데이터 부족으로 음수 R^2 (모델이 단순 평균보다 못함)
- 예측 오차가 더 크고 안정적이지 않음

--- RandomForestRegressor ---

MAE: 0.0017

RMSE: 0.0027

R2: 0.6350

--- LGBMRegressor ---

MAE: 0.0042

RMSE: 0.0053

R2: -0.4354

→ 회귀 모델로 사고율을 예측하려면 **데이터 포인트(자치구 수)가 너무 적음**

→ 피처 엔지니어링(로그 변환·더 많은 변수) 또는 데이터 확대(다년치·세분화) 필요

분류/예측 모델링

예측 모델링

② 분류 모델 (고위험 지역 예측)

모델

- RandomForestRegressor
- XGBoostClassifier

평가 지표

- Precision / Recall / F1-Score (classification_report)
- ROC AUC Score

```
# — (2) 분류 모델로 고위험 지역 예측 —  
from sklearn.ensemble import RandomForestC  
from sklearn.metrics import classification
```

```
# 상위 20% 사고율을 고위험(label=1)으로 분류  
threshold = merged_df['accident_rate'].quan  
merged_df['high_risk'] = (merged_df['accide
```

```
X_clf = merged_df[features]  
y_clf = merged_df['high_risk']
```

```
Xc_train, Xc_test, yc_train, yc_test = tra  
X_clf, y_clf, test_size=0.2, stratify=y  
)
```

```
# RandomForestClassifier  
rf_clf = RandomForestClassifier(n_estimator  
rf_clf.fit(Xc_train, yc_train)  
yc_pred = rf_clf.predict(Xc_test)  
yc_proba = rf_clf.predict_proba(Xc_test)[:
```


```
print("RandomForestClassifier\n", classific  
print("ROC AUC:", roc_auc_score(yc_test, yc
```


분류/예측 모델링

예측 모델링

② 분류 모델 (고위험 지역 예측) 출력 결과

RandomForestClassifier				
	precision	recall	f1-score	support
0	0.80	1.00	0.89	4
1	0.00	0.00	0.00	1
accuracy			0.80	5
macro avg	0.40	0.50	0.44	5
weighted avg	0.64	0.80	0.71	5
ROC AUC: 1.0				



분류/예측 모델링

예측 모델링

② 분류 모델 (고위험 지역 예측) 출력 결과

정밀도·재현율

- Class 0(저위험)은 대부분 정확히 예측했음 (recall=1.00)
- Class 1(고위험)은 전혀 예측 못함 (support=1) → recall=0.00

ROC AUC = 1.0

- 확률 출력은 잘 분리하지만, 임계값(0.5) 설정 때문에 모두 음성으로 분류

--- RandomForestRegressor ---

MAE: 0.0017

RMSE: 0.0027

R2: 0.6350

--- LGBMRegressor ---

MAE: 0.0042

RMSE: 0.0053

R2: -0.4354

→ 클래스 불균형(고위험 20% → 1개 샘플)

→ 교차검증 및 더 큰 데이터셋으로 재평가필요

프로젝트 개요

EDA (분포/이상치/상관관계)

프로젝트 구성 및 설계

공간 시각화

Dataset 개요

클러스터링 & 프로파일

데이터 전처리 및 파생지표 생성

분류, 예측 모델링

상관관계 분석

→ 가설 검증 & 정책 제안

가설 검증


결론 및 추가 모니터링

가설 검증 및 정책 제언

가설 검증

가설 1:

면허율이 높을수록 사고율이 낮다



- 예상과 정반대 결과: 면허율이 높은 자치구일수록 사고율도 높게 나타남
- 운전 가능 인구가 많아 교통량·혼잡도가 증가 → 사고 발생 기회 증가


→ “면허 보급 확대”만으로는 사고 예방 효과를 기대하기 어려움

→ 면허율이 높은 지역에 교통량 관리, 안전 교육 강화 병행 필요

가설 검증 및 정책 제언

가설 검증

가설 1 확장 히트맵




면허 보급률은 사고 발생 빈도와 직결되나,
“차량당 사고 효율”은 독립 변인으로 분리 고려

가설 검증 및 정책 제언

가설 검증

가설 2:

1인당 GRDP가 높을수록 사고율이 낮다



- 가설과 반대로, 1인당 GRDP가 높은 자치구일수록 사고율이 오히려 높음
- 경제력이 높은 지역일수록 교통량·활동량 증가로 사고 발생 위험 상승 가능성


→ 단순 경제력만으로 “안전”을 보장하지 않음

→ 고GRDP 지역에 교통 혼잡 관리, 안전 인프라 강화 필요

가설 검증 및 정책 제안

가설 검증

가설 2 확장 히트맵




경제력(1인당 GRDP, 총 GRDP)이 높을수록 사고율도 높아지는 역설적 양상관
정책 설계 시 경제 규모뿐 아니라 사고 부담 비율도 함께 고려해야 함

가설 검증 및 정책 제안

가설 검증

가설 3:

차량 1대당 사고 발생률이 높은 지역은
고위험 클러스터(Cluster 0)로 분류된다.



가설 3이 지지됨

고위험 클러스터(Cluster 0)는 차량 1대당 사고율이 유의미하게 높음


→ Cluster 0 지역에 교차로 안전 개선 및 속도제한 강화

→ 운전자 교육·교통 모니터링 집중 배치

가설 검증 및 정책 제안

가설 검증

가설 3 확장 히트맵



- 고위험 클러스터(Cluster 0)는 → 차량 밀집도↑, 면허율↑, 사고율↑
- 저위험 클러스터(Cluster 1) → 차량 밀집도·면허율 낮음

정책 제안 및 실행 로드맵

결론 및 추가 모니터링

1. 고위험 클러스터 (Cluster 0) 대상 맞춤 대책

- 높은 면허율과 차량 보유율 → 실제 운전자/차량 밀집
- 사고율과 사고당 피해 비율 모두 높은 구조
- 인프라 대비 운전자 밀집도가 높아 위험 발생 가능성 큼

111123: 종로구

111231: 영등포구

111261: 강남구

111262: 서초구

1. 고위험 클러스터 (Cluster 0) 대상 맞춤 대책

①

고위험군 대상 운전 습관 개선 교육 강화

정기 면허 재교육 제도 운영
사고다발 클러스터의 고령자,
고령·신규 면허자 대상으로 재교육 운영

②

도로 인프라 강화

- 스마트 교통 제어 인프라 확대
AI 신호제어, 차로별 사고 예측 시스템 도입
- 도로 인프라 강화
- 교차로 리모델링 및 차로 분리대 설치
 - 표지판·속도제한 시설 확충

③

고빈도 사고 유형 분석 기반 캠페인

- 고빈도 사고 유형 교육 콘텐츠 배포
차대차&차대인 사고 유형별 맞춤 콘텐츠 배포
- 자치구별 속도 제한 정책 조정
보행자 밀집 구역 중심으로 낮은 제한속도 설정

2. 저위험 클러스터 (Cluster 1) 대상 보완 대책

- 사고율 낮고, 저면허·저위험 그룹
- 차량 밀집도 낮고 대중교통 중심일 가능성 큼



111131: 용산구	111212: 강서구
111141: 광진구	111221: 구로구
111142: 성동구	111241: 동작구
111151: 중랑구	111251: 관악구
111152: 동대문구	111273: 송파구
111161: 성북구	111274: 강동구
111171: 도봉구	111281: 금천구
111181: 은평구	111291: 강북구
111191: 서대문구	111301: 양천구
111201: 마포구	111311: 노원구

2. 저위험 클러스터 (Cluster 1) 대상 보완 대책

①

자율주행·스마트 통신 인프라 테스트베드로 육성

사고율이 낮은 지역을 신기술 도입에 활용
보행자가 많은 상습 혼잡 구간에 AI 기반 교통량 예측 통제

지역사회 참여형 안전 문화 조성
주민이 직접 '위험 구간' 신고 후, 대응하는 대응 매커니즘 구축

②

도시 디자인 기반 안전 환경 유지

스마트 교통 제어 인프라 확대
AI 신호제어, 차로별 사고 예측 시스템 도입

스마트 공유 모빌리티 확산
기존 대중교통이 닿기 어려운 이면도로/주택가까지 서비스 범위 확대

③

고빈도 사고 유형 분석 기반 캠페인

고빈도 사고 유형 교육 콘텐츠 배포
차대차&차대인 사고 유형별 맞춤 콘텐츠 배포

자치구별 속도 제한 정책 조정
보행자 밀집 구역 중심으로 낮은 제한속도 설정

감사합니다:)

소프트웨어융합학과 2021111402 이예은

종합설계프로젝트 중간발표 · 2025.06.18